



経験的に推定した不確実性分布に基づく 時系列予測のための拡散モデルの反復的なデコーディング戦略

上野 航希 牧野 晃平 佐々木 裕
豊田工業大学 知能数理研究室

uenokouki.soccer@gmail.com, {sd21505, yutaka.sasaki}@toyota-ti.ac.jp

概要


- 不確実性サンプリングの概念を時系列拡散モデルのデコーディング戦略へ導入し
より確信度の低い部分を重点的に改善するアプローチを提案
- 不確実性の高い予測点を反復的にリサンプリング

結果と今後の課題

- 結果：8個中7個のベンチマークデータセットで予測精度の向上を達成
 - ノイズが多いデータセットでは改善が見られなかった
- 今後の課題：他の時系列拡散モデルへの応用が可能か検証する


時系列予測

- 時系列予測：過去の時系列データから将来の系列を予測するタスク
 - 深層時系列予測が高い予測性能を達成 [1]
- 拡散モデル [2]が時系列補完タスクなどで高品質なデータ生成に成功 [3]
⇒ 拡散モデルによる時系列予測タスクでは高精度な予測に至っていない [4]
⇒ 拡散モデルの能力を引き出せていない為、事前実験で失敗した予測を分析



事前実験

- 拡散モデルは多様な生成が可能な一方で生成系列が正解系列から逸脱する傾向
- 学習したデータ分布の中で極めて高い確率のデータを選択している可能性
⇒ デコーディングが原因で生成系列が単調な出力に偏ると予想
⇒ 予測の多様性を保ちつつ、高精度な予測を実現したい



提案手法

時系列拡散モデルの反復的デコーディング戦略 EUGID;

Empirically estimated Uncertainty-Guided Iterative Decoding strategy


- 順方向拡散過程でノイズを追加し、不確実性を表現
- 逆方向拡散過程でノイズを除去し、不確実性の中から予測をサンプリング

EUGID のモチベーション


- 推定した不確実性に従って ϵ を加えることで、予測の多様性を保つ [5]
- 確信度の低い点を反復的に予測し、予測精度の向上を図る [6]

経験的な不確実性分布の推定

- 各時点 l における予測の分散 $\hat{\sigma}_l$ として不確実性を推定
 - 【線形・指数】長期的な予測ほど不確実性が増大するという時系列予測の特性を仮定した不確実性
 - 【履歴】逆方向拡散時の予測の振動回数を追跡することで多く迷う予測ほど不確実性が増大すると仮定した不確実性



実験：EUGIDの予測精度評価



- 評価対象：8つの時系列予測の標準ベンチマーク [4, 7]に対するMSE
- 比較する既存手法：CSDI; Conditional Score-based Diffusion Model [3]
- 入力系列長：168
- 予測系列長：24
- 結果
 - Electricity を除く7つのデータセットで EUGID は従来手法を上回った
 - ETTh2 においては MSE が約 67% 削減される大幅な改善が観測された
 - 不確実性の推定方法による予測精度の差では線形推定法と指数推定法の間に大きな違いは見られなかったが履歴ベースの推定法はさらなる改善をもたらした
 - EUGID に適していることが示唆された

解析：EUGIDの予測性能の可視化

- 予測に成功した例
 - Wind (反復初期) (反復中期) (反復終盤) (最終予測)
 - EUGID (線形) (反復初期) (反復中期) (反復終盤) (最終予測)
 - EUGID (指数) (反復初期) (反復中期) (反復終盤) (最終予測)
 - EUGID (履歴) (反復初期) (反復中期) (反復終盤) (最終予測)
- 予測に失敗した例
 - Weather (反復初期) (反復中期) (反復終盤) (最終予測)
 - EUGID (線形) (反復初期) (反復中期) (反復終盤) (最終予測)
 - EUGID (指数) (反復初期) (反復中期) (反復終盤) (最終予測)
 - EUGID (履歴) (反復初期) (反復中期) (反復終盤) (最終予測)
- 失敗した予測の解析
分布の尖度が高い = ノイズが多い Electricity では精度向上が見られなかった

データセット	Electricity	ETTh1	ETTh2	Weather	Wind
尖度	3.987	0.413	-0.746	-1.591	0.257

参考文献

- [1] Liu et al., iTransformer: Inverted Transformers Are Effective for Time Series Forecasting, ICLR 2024.
[2] Ho et al., Denoising Diffusion Probabilistic Models, NIPS 2020.
[3] Kolloviev et al., Predict, Refine, Synthesize: Self-Guiding Diffusion Models for Probabilistic Time Series Forecasting, NIPS 2023.
[4] Tashiro et al., CSDI: conditional score-based diffusion models for probabilistic time series imputation, NIPS 2021.

- [5] Sadat et al., CADs: Unleashing the Diversity of Diffusion Models through Condition-Annealed Sampling, ICLR 2024.
[6] Raj et al., Uncertainty Sampling for Active Learning, PMLR 2023.
[7] Shen et al., Non-autoregressive conditional diffusion models for time series prediction, ICML 2023.